

# Métricas estadísticas aplicadas a los procesos organizacionales

Describir, detectar y decidir con datos

Joaquín Romano    Juan da Torre

Laboratorio de Métodos Cuantitativos Aplicados a la Gestión  
Universidad de Buenos Aires

Segundo cuatrimestre 2026

**Objetivo:** describir un proceso con números, detectar cuándo algo se salió de lo normal y saber *qué preguntar* antes de informar un resultado.

# Objetivo de la clase

## ¿Qué vamos a ver hoy?

- El promedio y sus trampas: media, mediana y asimetría.
- Dispersión: el número que nadie mira y que define el riesgo.
- Cuartiles, boxplot y detección de *outliers*.
- Datos faltantes: qué hacer cuando la celda está vacía.
- Correlación: qué mide, qué **no** mide y sus tres trampas.
- Un caso completo: ¿el proceso está bajo control?

Todo se implementa en Python con `pandas`, sobre datos de una organización.

# Por qué esto importa en una organización

Una métrica estadística no es un ejercicio: es **la forma de contestar preguntas de gestión** cuando los datos son demasiados para mirarlos de a uno.

## La pregunta del negocio

- ¿Cómo nos fue este mes?
- ¿Es parejo entre sucursales?
- ¿Esta venta es rara o normal?
- ¿El proceso está estable?

## La herramienta

- Media y mediana
- Desvío y coeficiente de variación
- Cuartiles y regla del IQR
- Gráfico de control

*Un número sin interpretación no resuelve nada.*

# El promedio y sus trampas

Media, mediana y asimetría

# Las tres medidas de tendencia central

## Definiciones

**Media** El promedio:  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ . Usa **todos** los valores.

**Mediana** El valor del medio cuando se ordenan los datos. Deja 50 % a cada lado.

**Moda** El valor que más se repite. Es la única que sirve para variables de texto.

## La diferencia clave

La **media** se mueve con cada dato extremo. La **mediana** no: hay que mover la mitad de los datos para correrla.

## Cuando el promedio miente

**Sueldos de un área de 10 personas** (en miles de pesos):

|     |     |     |     |     |      |      |      |      |             |
|-----|-----|-----|-----|-----|------|------|------|------|-------------|
| 800 | 850 | 900 | 900 | 950 | 1000 | 1050 | 1100 | 1200 | <b>9500</b> |
|-----|-----|-----|-----|-----|------|------|------|------|-------------|

Media

$$\bar{x} = 1825$$

**Nadie** gana eso: ni el que menos ni la mayoría.

Mediana

$$Me = 975$$

Describe bien al empleado *típico*.

*Un solo dato (el gerente) movió el promedio un 87 %.*

# Asimetría: el número que avisa

La **asimetría** (*skewness*) mide hacia qué lado se estira la distribución.

| Si...                 | Forma               | Qué significa                          |
|-----------------------|---------------------|----------------------------------------|
| Asimetría $\approx 0$ | simétrica           | Media y mediana coinciden              |
| Asimetría $> 0$       | cola a la derecha   | Pocos valores muy altos tiran la media |
| Asimetría $< 0$       | cola a la izquierda | Pocos valores muy bajos tiran la media |

## En Python

```
ventas["Total"].skew()
```

Casi todas las variables de plata (ventas, sueldos, patrimonios) son **asimétricas a la derecha**.

# La regla práctica

## ¿Media o mediana?

- 1 Calculá las dos.
- 2 Si se **parecen**, la distribución es simétrica: usá la media.
- 3 Si **difieren mucho**, hay valores extremos: informá la **mediana** y aclarálo.

## Para la reunión

Cuando alguien presenta “el promedio” de algo, la pregunta correcta es siempre la misma: **¿cuánto da la mediana?** Si no la calculó, no sabe si su promedio representa algo.



# Dispersión

El número que nadie mira

# Medir cuánto se mueven los datos

## Las tres medidas

**Rango**  $\text{máx} - \text{mín}$ . Simple, pero lo define un solo dato.

**Varianza**  $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$ . Queda en unidades *al cuadrado*.

**Desvío estándar**  $s = \sqrt{s^2}$ . Vuelve a las unidades originales: **es el que se informa**.

*La media dice dónde está el centro. El desvío dice cuánto se puede confiar en ese centro.*

# El desvío estándar, en criollo

## Cómo se lee

El desvío es **la distancia típica de un dato al promedio**.

Si las ventas promedian \$100.000 con un desvío de \$8.000, la venta habitual anda **entre \$92.000 y \$108.000**.

## La regla empírica (distribución simétrica)

$\bar{x} \pm 1s$  contiene  $\approx 68\%$  de los datos

$\bar{x} \pm 2s$  contiene  $\approx 95\%$

$\bar{x} \pm 3s$  contiene  $\approx 99,7\%$

Esa última fila es la base del **gráfico de control** que vemos al final.

## Coeficiente de variación

¿Cómo comparo la variabilidad de cosas medidas en unidades distintas?

$$CV = \frac{s}{\bar{x}} \times 100$$

### Para qué sirve


Es el desvío expresado **como porcentaje del promedio**. Al no tener unidades, permite comparar la estabilidad de una sucursal grande contra una chica, o de las ventas contra los costos.

|                | Sucursal Centro | Sucursal Norte |
|----------------|-----------------|----------------|
| Venta promedio | \$ 480.000      | \$ 95.000      |
| Desvío         | \$ 48.000       | \$ 19.000      |
| <b>CV</b>      | <b>10 %</b>     | <b>20 %</b>    |

Norte vende menos y es el doble de impredecible.

# El mismo promedio, dos realidades

Dos sucursales facturan, en promedio, exactamente lo mismo:



## La pregunta de gestión

¿Cuál de las dos sucursales preferís? La **A** se puede planificar: stock, personal y caja. La **B** obliga a estar preparado para el peor día. **Mismo promedio, riesgo distinto.**

# Cuartiles y boxplot

Ver la distribución de un vistazo

# Percentiles y cuartiles

## Definición

El **percentil**  $p$  es el valor que deja por debajo al  $p\%$  de los datos. Los **cuartiles** son los percentiles 25, 50 y 75.

| Cuartil | Es el...     | Significa                            |
|---------|--------------|--------------------------------------|
| $Q_1$   | percentil 25 | El 25 % de los datos está por debajo |
| $Q_2$   | percentil 50 | <b>Es la mediana</b>                 |
| $Q_3$   | percentil 75 | El 75 % está por debajo              |

## En Python

```
total.quantile(0.25) . total.describe()
```

# El rango intercuartílico

$$IQR = Q_3 - Q_1$$

## Qué mide


El ancho del **50 % central** de los datos. Es una medida de dispersión que **ignora los extremos**: por eso no se deja arrastrar por un dato raro.

|                 | Se ve afectado por extremos | Cuándo usarlo            |
|-----------------|-----------------------------|--------------------------|
| Desvío estándar | Sí                          | Distribución simétrica   |
| IQR             | No                          | Hay outliers o asimetría |

Misma lógica que media vs. mediana: uno es sensible, el otro es robusto.



# Cómo se lee un boxplot



## Lo que hay que mirar

**Si la mediana no está en el centro de la caja, la distribución es asimétrica.** Y si un bigote es mucho más largo que el otro, hay cola de ese lado.

# Outliers

Los casos raros

## La regla del $1,5 \cdot IQR$

Un dato es **outlier** si cae fuera de estos límites:

$$\text{Límite inferior} = Q_1 - 1,5 \cdot IQR \quad \text{Límite superior} = Q_3 + 1,5 \cdot IQR$$

### De dónde sale el 1,5

Es una **convención**, no una ley. Con datos simétricos, esos límites dejan afuera aproximadamente el 0,7 % de las observaciones. Se puede usar 3 en lugar de 1,5 para marcar solo los casos extremos.

### En Python

```
iqr = q3 - q1  
outliers = serie[(serie < q1 - 1.5*iqr) | (serie > q3 + 1.5*iqr)]
```

# Un outlier NO se borra automáticamente

## El error más caro de la clase

Borrar los outliers “porque ensucian el análisis” es, muchas veces, **borrar justo la información más valiosa**.

## Las tres preguntas, en orden

- 1 **¿Es un error de carga?** Una venta de \$0 o una edad de 200 años se corrige o se saca.
- 2 **¿Es un caso real y relevante?** El cliente que compra 50 veces más que el resto **existe** y probablemente sea el más importante.
- 3 **¿Qué pasa con y sin él?** Corré el análisis de las dos formas e informá la diferencia.

El fraude, las fallas y los mejores clientes **son** outliers.

# Datos faltantes

Cuando la celda está vacía

# Que falte un dato también es un dato

Lo primero: contarlos

```
df.isnull().sum() . df.info()
```

Y lo segundo, más importante: ¿por qué faltan?

Al azar Se perdieron por un problema técnico. Son los menos peligrosos.

Con patrón **Faltan por una razón**, y esa razón suele importar.

El ejemplo que lo explica todo

En una base de créditos, la relación deuda/ingreso falta más seguido en los clientes que **terminaron en default**. El dato faltante *predice* el resultado: borrar esas filas elimina el patrón más informativo de la base.

## Qué hacer con los faltantes

| Estrategia                    | Cuándo                                | Riesgo                      |
|-------------------------------|---------------------------------------|-----------------------------|
| Borrar filas                  | Faltan pocas y al azar                | Perder información y sesgar |
| Imputar (media/mediana)       | Variable numérica, pocos faltantes    | Reduce la variabilidad real |
| Categoría “sin dato”          | Variable de texto                     | Ninguno grande              |
| <b>Marcar con una bandera</b> | <b>Siempre que se sospeche patrón</b> | Ninguno                     |

### La bandera: dos líneas que salvan un análisis

```
df["falta_ingreso"] = df["ingreso"].isnull()
df["ingreso"] = df["ingreso"].fillna(df["ingreso"].median())
```

Así imputás y conservás la información de que ese dato faltaba.

# Correlación

Qué mide y qué no



# El coeficiente de correlación

Mide la fuerza y el sentido de la relación **lineal** entre dos variables. Va de  $-1$  a  $1$ .

| Valor          | Qué indica                    |
|----------------|-------------------------------|
| $r \approx 1$  | Cuando una sube, la otra sube |
| $r \approx 0$  | No hay relación <i>lineal</i> |
| $r \approx -1$ | Cuando una sube, la otra baja |

## En Python

```
df[["Cantidad", "Precio", "Total"]].corr()
```

Como referencia: por encima de  $0,7$  se considera una relación fuerte.

# Las tres trampas de la correlación

## 1. Correlación no es causalidad

Que dos cosas se muevan juntas no significa que una cause la otra. Puede haber una **tercera variable** moviendo a las dos, o ser pura coincidencia.

## 2. Solo detecta relaciones lineales


Una relación **perfecta** pero curva puede dar correlación cero.

## 3. Un solo outlier la distorsiona

Un punto extremo puede crear una correlación que no existe, o tapar una que sí.

**Por eso la regla es siempre la misma: graficá antes de creerle al número.**

## Correlación cero, relación perfecta



### Lo que pasa acá

La relación es **perfecta y evidente**: es una parábola. Pero como no es una recta, el coeficiente de correlación da prácticamente **cero**.


Si solo mirabas el número, concluías que “no hay relación”.

*El coeficiente responde “¿hay relación lineal?”, no “¿hay relación?”.*

# ¿El proceso está bajo control?

Todo junto, en un caso

# El gráfico de control



## Cómo se arma

Se dibuja la **media** del proceso y dos límites en  $\bar{x} \pm 3s$ . Mientras los puntos caigan adentro, la variación es la **normal del proceso**. Un punto afuera avisa que **algo cambió** y hay que ir a buscar la causa.

# Ideas clave de la clase

## Para llevarse

- 1 **Nunca informes una media sola.** Sin la mediana y el desvío, un promedio no describe nada.
- 2 **La dispersión es el riesgo.** Dos procesos con la misma media pueden ser negocios completamente distintos.
- 3 **Un outlier es una pregunta, no un estorbo.** Antes de borrarlo, averiguá qué es.
- 4 **Que falte un dato es información.** Marcá el faltante antes de imputarlo.
- 5 **Graficá antes de creerle a un coeficiente.**

*La estadística descriptiva no adorna el informe: es la que decide qué se puede afirmar.*