Simulación de Datos y Muestreo

Cuánto podemos confiar en una muestra, y cómo simular para averiguarlo

Juan Ignacio da Torre

Laboratorio de Métodos Cuantitativos Aplicados a la Gestión
Universidad de Buenos Aires

Segundo cuatrimestre 2026

Objetivo: entender cuánto se equivoca una muestra y qué hacer para que se equivoque poco

Cómo vamos a trabajar

Esta presentación va acompañada de un notebook

Las dos cosas se recorren **en paralelo**: acá el concepto y la cuenta a mano, y en el notebook lo hacemos correr.

En la presentación

- La idea de cada concepto
- Las fórmulas, paso a paso
- Los resultados que vamos a ver

En el notebook

- Una población de 100.000 clientes
- Miles de muestras simuladas
- Ejercicios con solución

`notebooks/19_Simulacion_de_datos_y_muestreo.ipynb`

De dónde venimos y a dónde vamos

Clase 06: cómo muestrear

Aleatorio simple, porcentual, por filtro, estratificado y por conglomerados, con `.sample()` de pandas.

Hoy: cuánto confiar

- ¿Cuánto se equivoca una muestra?
- ¿Qué tamaño necesito?
- ¿Cómo elijo para equivocarme menos?
- ¿Qué pasa si elijo mal?

Para responder: simular

En la vida real no conocemos la verdad. Si **fabricamos** la población, sí la conocemos, y podemos ver cuánto se equivoca cada muestra.

Población, muestra, parámetro y estadístico



Concepto	Ejemplo
Población	los 100.000 clientes
Muestra	100 clientes elegidos
Parámetro	gasto promedio verdadero
Estadístico	gasto promedio de la muestra

Error muestral = estadístico − parámetro.
No es una equivocación: es el desvío inevitable por mirar solo una parte.

Nuestro mundo simulado: la base de clientes

Variable	Cómo se genera	Valor verdadero
Segmento	60 % Básico · 30 % Medio · 10 % Premium	—
Canal	35 % Online · 65 % Sucursal	35,3 % Online
Gasto mensual	lognormal: cola larga hacia arriba	**promedio $94.566** mediana $69.984 desvío σ = $74.343

La semilla

Los números "al azar" de la computadora salen de una fórmula: con la misma **semilla** salen siempre los mismos. Por eso fijamos una semilla: así el resultado se puede repetir y defender.

Una muestra, un error; otra muestra, otro error

Cinco muestras de 100 clientes, sacadas de la misma población (verdad: \$94.566):

Muestra	Promedio	Error
1	\$91.874	−2.691
2	\$111.307	+16.741
3	\$103.126	+8.560
4	\$100.016	+5.450
5	\$90.002	−4.564

La pregunta

Cada muestra da un número distinto. ¿Qué tan distintos? Para saberlo: sacar **mil** muestras.

Mil muestras: la distribución muestral

Repetimos 1.000 veces con $n = 10$, $n = 100$ y $n = 1.000$, y guardamos cada promedio:

1. Sin sesgo

Los promedios se agrupan alrededor del valor verdadero. No se equivocan para ningún lado.

2. Más *n*, menos dispersión

Con $n = 10$ los promedios van de un extremo al otro; con $n = 1.000$ están pegados a la verdad.

3. Forma de campana

Aunque el gasto tiene cola larga, los *promedios* forman una campana: **teorema central del límite**.

El error estándar y la regla de la raíz

Error estándar de la media

$$EE = \frac{\sigma}{\sqrt{n}}$$

A mano, con $\sigma = 74.343$:

$$n = 10: \quad \frac{74.343}{\sqrt{10}} = 23.509$$

$$n = 100: \quad \frac{74.343}{\sqrt{100}} = 7.434$$

$$n = 1.000: \quad \frac{74.343}{\sqrt{1.000}} = 2.351$$

n	Simulado	Teórico
10	22.627	23.509
100	7.306	7.434
1.000	2.362	2.351

Para dividir el error por 2, hay que cuadruplicar la muestra

n está dentro de una raíz: $\sqrt{4n} = 2\sqrt{n}$.

¿Qué tamaño de muestra necesito?

Con confianza del 95 %, la estimación cae a menos de 1,96 errores estándar de la verdad:

$$\text{margen de error} = 1{,}96 \cdot \frac{\sigma}{\sqrt{n}}$$

n	**Error estándar**	**Margen (95 %)**	**Margen en % del promedio**
25	14.869	29.142	30,8 %
100	7.434	14.571	15,4 %
400	3.717	7.286	7,7 %
1.600	1.859	3.643	3,9 %
6.400	929	1.821	1,9 %

Cada fila cuadruplica a la anterior y el margen se divide a la mitad.

Para una proporción: el caso de las encuestas

$$\text{margen} = 1{,}96\sqrt{\frac{p(1-p)}{n}} \qquad \Longrightarrow \qquad n = \frac{1{,}96^2\, p\,(1-p)}{\text{margen}^2}$$

A mano: sin idea de p se usa el peor caso, $p = 0{,}5$.
Margen $\pm 3\,\%$:

$$n = \frac{3{,}8416 \times 0{,}25}{0{,}03^2} = \frac{0{,}9604}{0{,}0009} \approx 1.068$$

Caso	n
$p = 0{,}5$, $\pm 3\,\%$	1.068
$p = 0{,}35$, $\pm 2\,\%$	2.185
$p = 0{,}5$, $\pm 1\,\%$	9.604

Lo que sorprende

El tamaño de la población casi no importa: para el mismo margen, una ciudad de 100.000 y un país de 40 millones necesitan prácticamente la misma muestra. Importa la **precisión** que querés.

Cinco maneras de elegir a quién preguntar

Método	**Cómo se elige**
Aleatorio simple	Todos tienen la misma chance: sorteo de toda la lista
Estratificado por segmento	Grupos Básico, Medio y Premium; se sortea dentro de cada uno, en proporción a su peso (120, 60 y 20 de 200)
Estratificado por ciudad	Lo mismo, con una cuota por ciudad
Sistemático	Uno cada k de la lista, con arranque al azar
Por conveniencia	A quien es fácil de alcanzar: acá, solo los clientes Online

Comparamos $n = 200$, repetido 2.000 veces con cada método. Verdad: \$94.566.

Quién se equivoca más, y para dónde

Método	Promedio de las estimaciones	Sesgo	Desvío entre muestras
Aleatorio simple	94.723	+158	5.199
Estratificado por segmento	94.633	+67	**3.043**
Estratificado por ciudad	94.524	−42	5.280
Sistemático	94.479	−87	5.247
Por conveniencia (Online)	**110.515**	+15.949	5.894

Estratificar por segmento

Baja el error un **41 %**: los segmentos son muy distintos entre sí, y asegurar que cada uno esté en su proporción elimina la variación de "cuántos premium me tocaron".

Estratificar por ciudad

No mejora nada: las ciudades gastan lo mismo. Se estratifica por una variable *relacionada* con lo que se mide.

El sesgo no se arregla con más datos

Muestra por conveniencia: solo clientes Online.

n	Error vs. la verdad
200	+12.919
1.000	+18.869
5.000	+15.509
20.000	+15.927

La lección

Más n achica el error **aleatorio**, pero no toca el error **sistemático**.
Una muestra grande y mal elegida da una respuesta equivocada **con mucha confianza**.

Es el error clásico de las encuestas por redes, los comentarios de una app o "los clientes que se quejan".

Simulación de Monte Carlo

La idea, en cuatro pasos

1. Definir un modelo con variables **inciertas**.
2. **Sortear** valores para esas variables, miles de veces.
3. Calcular el resultado en cada sorteo.
4. Mirar la **distribución** de resultados, no un solo número.

Calentamiento: estimar π tirando 100.000 puntos al azar en un cuadrado de lado 1. El cuarto de círculo ocupa $\pi/4$ del cuadrado, así que

$$\frac{\text{puntos adentro}}{\text{total}} \approx \frac{\pi}{4} \quad \Rightarrow \quad \pi \approx 4 \times 0{,}7855 = 3{,}1421$$

El horno de la panadería, con incertidumbre



Clase 14: inversión de \$10 millones, flujos 3/3,5/4/4/3, costo de capital 20 %.

$$VAN = -10 + \frac{3}{1{,}2} + \frac{3{,}5}{1{,}2^2} + \frac{4}{1{,}2^3} + \frac{4}{1{,}2^4} + \frac{3}{1{,}2^5} = +0{,}38$$

Conviene, pero *por poco*. Esa cuenta supone que los flujos serán **exactamente** esos.
Si cada flujo varía un 20 % alrededor de lo esperado, y simulamos 20.000 futuros:

¿Qué dice la simulación?

VAN promedio simulado	+0,38 M
Desvío del VAN	0,96 M
Rango central 90 %	−1,20 a +1,95 M
Probabilidad de VAN < 0	**34,5 %**

Moraleja

Un VAN de +0,38 parecía un buen proyecto.
Con incertidumbre, hay **una chance de cada tres** de perder plata.
Monte Carlo no reemplaza al VAN: lo **completa** con la pregunta *"¿qué tan seguro es?"*

Es lo que hicimos con Stargate Argentina: en vez de "2,8 % de la demanda", simulamos 10.000 escenarios y dijimos "entre 2,3 % y 3,3 %".

Más incertidumbre, más riesgo

Desvío de los flujos	VAN promedio	Probabilidad de perder
0 %	+0,38	0 %
10 %	0,38	20,9 %
20 %	0,39	34,2 %
30 %	0,38	39,6 %
40 %	0,37	42,1 %

El VAN **promedio** casi no cambia, pero la probabilidad de perder crece con la incertidumbre.

Bootstrap: remuestrear una sola muestra

En la vida real tenemos **una** muestra, no la población. El truco: sacar *de la muestra* nuevas muestras **con reposición**, del mismo tamaño, y ver cuánto varía el promedio.

	Desde	**Hasta**
Promedio de la muestra (n = 200)	$105.430	
Intervalo 95 % por bootstrap	$93.167	$119.559
Intervalo 95 % por fórmula	$92.380	$118.481
Promedio verdadero (no lo conocíamos)	**$94.566**	

Sin ninguna fórmula, el bootstrap da un intervalo casi igual, y que **contiene** a la verdad. Sirve incluso donde no hay fórmula (una mediana, un cociente).

Para llevarse

1. **Fijá la semilla**: sin ella no se puede repetir ni defender un resultado.
2. Una muestra aleatoria se equivoca **poco** (y menos cuanto más grande) y **sin sesgo**.
3. Para **dividir el error por 2**, cuadruplicá la muestra.
4. **Estratificá** por una variable relacionada con lo que medís; si no, no mejora nada.
5. El **sesgo no se arregla con más datos**: desconfiá de "la gente que respondió".
6. **Monte Carlo** mide el riesgo de una decisión: simular miles de futuros y mirar la distribución.

En el trabajo práctico

Si en tu TP...	**Hacé esto**
El dataset es enorme y tarda	Explorá con una muestra aleatoria **con semilla**, y confirmá al final con todo
Hay un grupo chico pero importante	**Estratificá**, para que no desaparezca
Los datos vienen de una encuesta o app	Preguntate **quién respondió**
Querés probar el código antes de los datos	**Simulá** datos con la misma forma
Vas a mostrar un promedio o un %	Acompañalo con su **margen de error**

En la metodología del informe, decí **cómo se obtuvieron los datos**: quién los generó, cuántos son y si son toda la población o una muestra.

Ejercicios (en el notebook, con solución)

1. **Dados.** Simulá 100.000 tiradas de dos dados: ¿con qué frecuencia suman 7? Compará con $6/36$.
2. **Tamaño de muestra.** ¿Qué n estima la proporción de clientes Online con $\pm 2\,\%$? Verificalo con 1.000 muestras.
3. **Estratificar o no.** Repetí la comparación estratificando por canal. ¿Mejora? ¿Por qué?
4. **Monte Carlo.** En el horno, ¿qué probabilidad de perder hay si el costo de capital sube al $25\,\%$?

Preguntas

¿Preguntas?

Fuentes

- Moore, D., McCabe, G., & Craig, B. (2017). *Introduction to the Practice of Statistics* (9th ed.). W. H. Freeman.
- Lohr, S. (2021). *Sampling: Design and Analysis* (3rd ed.). CRC Press.
- Efron, B., & Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Brealey, R., Myers, S., & Allen, F. (2020). *Principles of Corporate Finance* (13th ed.). McGraw-Hill. (Simulación de Monte Carlo en la evaluación de proyectos.)
- Clases 06 (muestreo), 14 (VAN y métricas) y 21 (métricas estadísticas) de este laboratorio.